


Taula de contingut

Format d'entrega	2
Exercici 1	3
Zeros	8
Dades buides	8
Dades nul·les.....	8
Exemple	9
Exercici 2	12
Exercici 3	12
Bibliografia.....	13



Format d'entrega

La documentació generada en la realització de la prova d'avaluació continuada es troba allotjada en **GitHub** al següent repositori:

- <https://github.com/rsanchezs/data-cleaning>

En aquest repositori es poden trobar els següents fitxers:

- Aquest document en formats **pdf** i **docx** amb el nom rsanchezs_PAC2.
- Tots els documents, gràfics, imatges i taules utilitzades en aquest PAC.


1. Nota: Propietat intel·lectual

Sovint és inevitable, al produir una obra multimèdia, fer ús de recursos creats per terceres persones. És per tant comprensible fer-lo en el marc d'una pràctica dels Estudis, sempre que això es documenti clarament i no suposi plagi en la pràctica.

Per tant, al presentar una pràctica que faci ús de recursos aliens, s'ha de presentar juntament amb ella un document en quin es detallin tots ells, especificant el nom de cada recurs, el seu autor, el lloc on es va obtenir i el seu estatus legal: si l'obra està protegida pel copyright o s'acull a alguna altra llicència d'ús (Creative Commons, llicència GNU, GPL ...).

L'estudiant haurà d'assegurar-se que la llicència no impedeix específicament el seu ús en el marc de la pràctica. En cas de no trobar la informació corresponent haurà d'assumir que l'obra està protegida per copyright.

Hauríeu de, a més, adjuntar els fitxers originals quan les obres utilitzades siguin digitals, i el seu codi font si correspon.



Exercici 1

Després de llegir el recurs “Clean Data”, contesta les següents preguntes amb les teves pròpies paraules.

1. Quines són les principals etapes d'un projecte analític en ciència de dades?. Descriu amb les teves paraules cadascuna de les etapes. Aquest procés ha de realitzar-se una sola vegada o per contra és un procés iteratiu? (màxim 250 paraules).

Tot seguit es mostra una figura amb la qual ens propositem exposar les diferents etapes d'un projecte analític.

Com es pot apreciar un projecte analític no és un procés que es dugui a terme en una sola fase i generalment s'ha de passar per diverses fases.

Aquestes fases són: entendre i expressar un objectiu, entendre les dades amb les que treballarem, preparació de les dades, modelatge, avaluació i desplegament. Convé fer ressaltar que, aquest procés no és lineal, sinó es realimenta i continua.

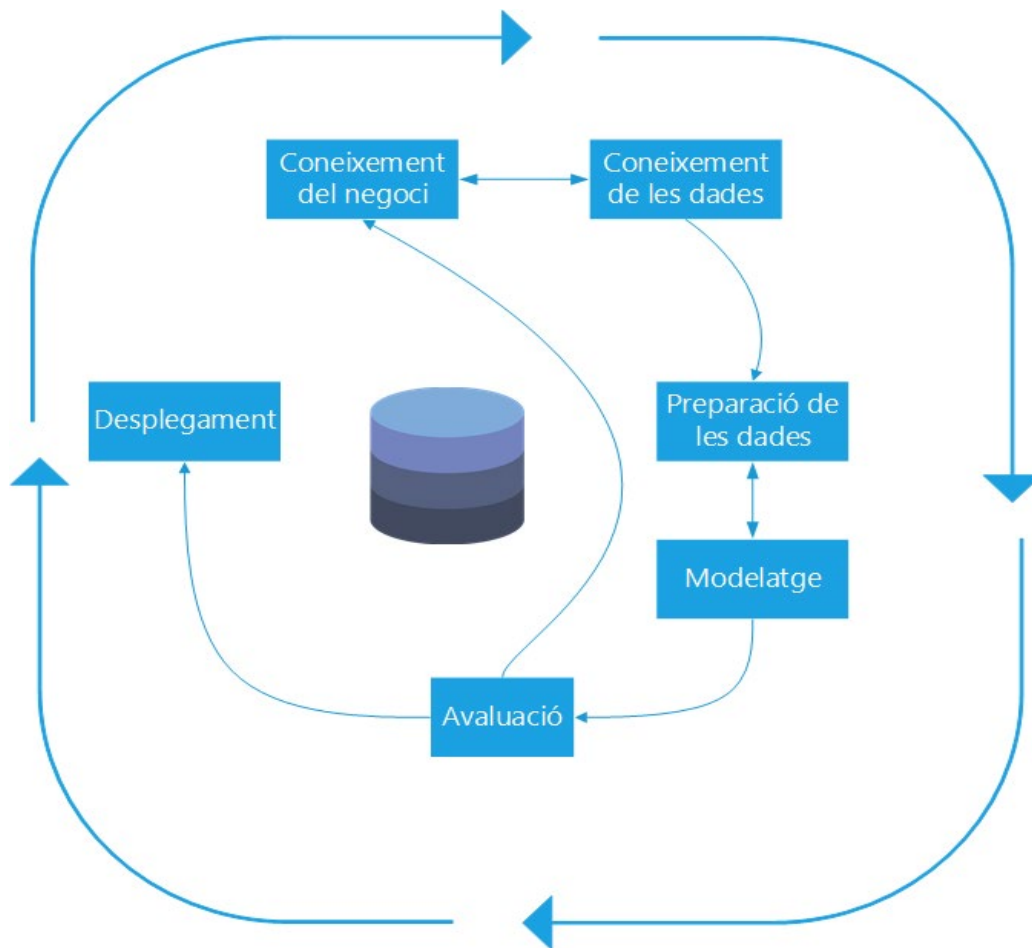


Fig. 1: Etapes d'un projecte analític



A continuació amb la següent taula es detallen les activitats que li corresponen a cada fase:

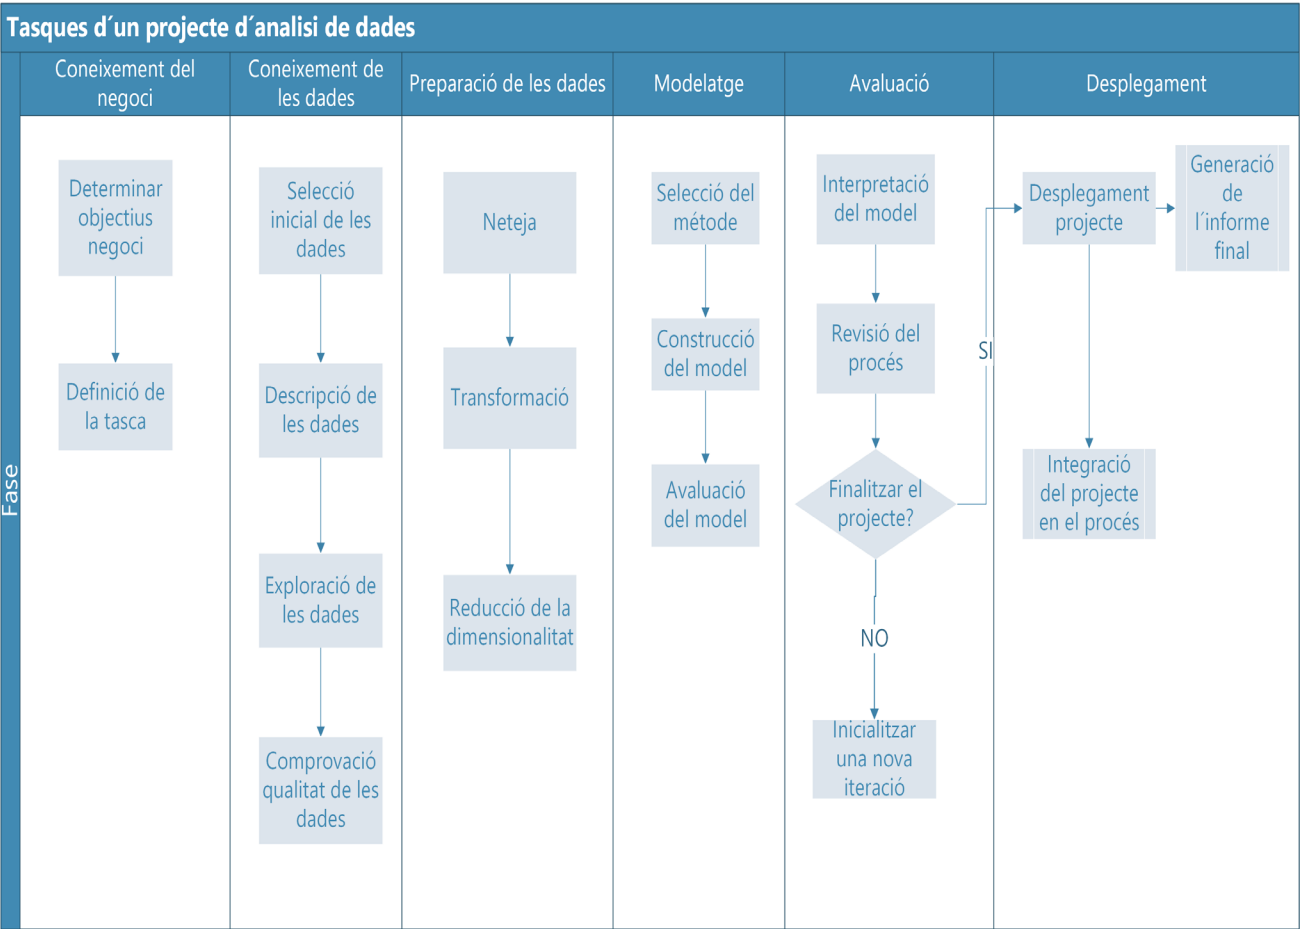


Fig. 2 Tasques d'un projecte analític











2. Suposa que es desitja transferir un grup arxius entre una empresa A i una altra empresa B. La primera treballa amb OSX i Linux com a sistema operatiu, mentre que la segona treballa amb Windows. Quin programa de compressió utilitzaria per a aquesta transmissió i per què? (màxim 100 paraules).

En primer lloc, convé fer ressaltar que quan es realitza una compressió d'un arxiu cal tindre en compte els següents factors:


- La velocitat de compressió i descompressió.
- El ratio de compressió.
- La interoperabilitat de la solucio de compressió.
- Escollir el software de compressió:
 - Zip
 - gzip
 - bzip2
 - RAR



En la següent taula es mostren les diferents opcions:

	Velocitat	Ratio	Interoperabilitat
gzip	Ràpida	Normal	 
bzip2	Lenta	Petit	 
zip	Normal	Alt	  
RAR	Lenta	Normal	

Com es pot apreciar en la taula la millor opció seria realitzar la compressió amb zip.



3. Explica amb les teves pròpies paraules, quina és la diferència entre els zeros, les dades buides i les dades nul·les?. Amb l'ajuda d'un exemple real on existeix una pèrdua de dades, explica quan han de col·locar-se zeros i quan aquestes dades es deixaran com a dades buides durant el procés de data cleaning (màxim 200 paraules).

Zeros

El valor zero es representa mitjançant el símbol **0**. Es tracta de un quantitat mesurable i que té un significat en un sistema numéric. Utilitzem zero quan ens referim a valors de tipus numéric.

Dades buides

Podem trobar-nos amb dades buides quan no es coneix el valor per aquest atribut. Ens podem trobar amb els diferents tipus:

- **Cadenes de caracters:** s'utilitza la cadena "Desconegut" o no aplicable **NA**.
- **Dades numériques:** com hem vist en l'apartat anterior s'utilitza el valor 0.
- **Data:** les dades que representen dates i que no coneixem es poden representar mitjançant una data llunyana (1900-01-01) o primerenca (9999-12-31) en el temps.

Dades nul·les

Les dades nul·les es representen mitjançant la paraula reservada **NULL** i ens indica que no existeix informació en un camp.



Aquesta falta d'informació pot venir o bé perquè no es aplicable o bé pel desconeixemnt del valor.

Exemple

A continuació, amb l'ajuda del conjunt de dades `diabetes` veurem com tractar els valors desconeguts:

```
# Importem el conjunt de dades
library(readr)
diabetes <- read_csv("../PAC2/data/diabetes.csv")
```

Realitzem un primer contacte amb el joc de dades, visualitzant la seva estructura i els 6 primers registres:

```
# Visualitzem les 6 primeres files
head(diabetes)

## # A tibble: 6 x 10
##   Pregnancies Glucose `Blood pressure` Skinfold Insulin  BMI
##   <int>      <int>          <int>      <int>    <int> <dbl>
## 1         6      148            72        35         0  33.6
## 2         1       85            66        29         0  26.6
## 3         8     183            64         0         0  23.3
## 4         1       89            66        23        94  28.1
## 5         0     137            40        35       168  43.1
## 6         5     116            74         0         0  25.6
## # ... with 4 more variables: `Diabetes pedigree` <dbl>, Age <int>,
## #   Diabetes <chr>, weight <int>
```

Amb la següent instrucció podem comprobar el nombre de valors desconeguts per a cada atribut:



```
# Comprobació de valors desconeguts
sapply(diabetes, function(x) sum(is.na(x)))

##      Pregnancies      Glucose      Blood pressure
Skinfold
##           11           0           0
0
##      Insulin      BMI Diabetes pedigree
Age
##           0           0           0
0
##      Diabetes      weight
##           0           0
```

Podem observar que, per a onze observacions, el camp **Pregnancies** no té cap valor assignat. Això podria ocórrer per diversos motius:

- El més senzill és que no s'hagi pogut obtenir aquesta informació, i en aquest cas podríem o bé emplenar aquests casos amb el valor més freqüent, o bé amb el valor mitjà.
- També podria ser que l'absència de valor per al camp embarassos ens indiqués que aquestes files corresponen a pacients masculins, pels quals el camp no té sentit.

En qualsevol d'aquests dos casos, hauríem de transformar el conjunt de dades. En el primer supòsit, afegint un valor per defecte que fos raonable:

```
# Mitjançant una condició lògica obtenim els valors desconeguts
missing_values_pregnancies <- is.na(diabetes$Pregnancies)
# Reemplacem els valors desconeguts amb 0
diabetes$Pregnancies[missing_values_pregnancies] <- 0
```





En el segon, creant un nou camp que contingui informació sobre si el pacient és un home o no.

```
# Carreguem les llibreries
library(tidyverse)
# Creem una nova columna amb el gènere
diabetes <- diabetes %>%
  mutate(Gender = ifelse(is.na(diabetes$Pregnancies), "Male"
, "Female"))
```

Amb el següent diagrama podem comprobar la distribució de la nova variable `Gender`:

```
# Visualitzem la distribució de la variable
diabetes %>% ggplot(aes(Gender)) +
  geom_bar(aes(fill = Gender)) +
  theme_minimal()
```





Exercici 2


Després de llegir el recurs “Data Mining: concepts and techniques” contesta les següents preguntes.

1. Explica amb les teves pròpies paraules quines són les principals etapes del pre-processament de dades (màxim 400 paraules). Posa un exemple d'un projecte analític i indica a grans trets que s'hauria de fer en cada etapa.
2. Explica breument amb les teves pròpies paraules, tres dels factors que poden influir en l'estimació de la qualitat de les dades (màxim 100 paraules).

Exercici 3

Després de llegir el recurs “Data Cleaning Basics”, contesta les següents preguntes:

1. Què es considera un extrem score ? Quins són els seus possibles efectes en els resultats finals? (màxim 150 paraules).
2. Explica dues possibles causes que poden donar lloc a l'aparició d'extrem scores i proposa una possible solució juntament amb un breu exemple pràctic per a cada cas (màxim 200 paraules).



Bibliografia

[1]:Megan Squire (2015). Clean Data . Packt Publishing Ltd. Capítols 1 i 2.

[2]:Jiawei Han, Micheine Kamber, Jian Pei (2012). Data mining: concepts and techniques . Morgan Kaufmann. Capítol 3.

[3]:Jason W. Osborne (2010). Data Cleaning Basics: Best Practices in Dealing with Extreme Scores. Newborn and Infant Nursing Reviews; 10 (1): pp. 1527-3369 .