


Tabla de contenido

Format d'entrega	2
Introducció	4
PART I Preparació de les Dades.....	7
Pre-processament de les Dades	7
Carrega i exàmen preliminar del conjunt de dades	7
Exploració i Tractament de Valors Desconeguts.....	10
Transformació d'atributs	13
Identificació d'Etiquetes Errònies en Variables Categòriques	17
Identificació de <i>outliers</i>	18
Transformació de les Dades	22
Reducció de la Dimensionalitat.....	25
Anàlisi Exploratori de les Dades	27
PART II Clustering.....	35
Requisits.....	35
Determinació del nombre de clústers.....	36
Mètode d'agregació <i>k-means</i>	39
PART III Classificació.....	45
El paquet Caret.....	45
Separació de dades: Conjunt d'entrenament i prova:	46
Classificació amb C50	48
Bibliografia	50



Format d'entrega

Aquest document s'ha realitzat mitjançant **Markdown**¹ amb l'ajuda de l'entorn de desenvolupament **RStudio**² utilitzant les característiques que aquest ofereix per a la creació de documents **R** reproduïbles.

La documentació generada en la realització de la pràctica es troba allotjada en **GitHub** al següent repositori:

- <https://github.com/rsanchezs/data-cleaning>

En aquest repositori es poden trobar els següents fitxers:

- Aquest document en formats **pdf** i **docx** amb el nom `rsanchezs_practica2`.
- Un document **R Markdown**³ que es pot utilitzar per a reproduir tots els exemples presentats a la PAC.
- El conjunt de dades utilitzades.

¹ <https://es.wikipedia.org/wiki/Markdown>

² <https://www.rstudio.com/>

³ <https://rmarkdown.rstudio.com/>



Nota: Propietat intel·lectual

Sovint és inevitable, al produir una obra multimèdia, fer ús de recursos creats per terceres persones. És per tant comprensible fer-lo en el marc d'una pràctica dels Estudis, sempre que això es documenti clarament i no suposi plagi en la pràctica.

Per tant, al presentar una pràctica que faci ús de recursos aliens, s'ha de presentar juntament amb ella un document en que es detallin tots ells, especificant el nom de cada recurs, el seu autor, el lloc on es va obtenir i el seu estatus legal: si l'obra està protegida pel copyright o s'acull a alguna altra llicència d'ús (Creative Commons, llicència GNU, GPL ...). L'estudiant haurà d'assegurar-se que la llicència no impedeix específicament el seu ús en el marc de la pràctica. En cas de no trobar la informació corresponent haurà d'assumir que l'obra està protegida per copyright. Hauríeu a més, d'adjuntar els fitxers originals quan les obres utilitzades siguin digitals, i el seu codi font si correspon

Un altre punt a considerar és que qualsevol pràctica que faci ús de recursos protegits pel copyright no podrà en cap cas publicar-se en Mosaic, la revista del Graduat en Multimèdia de la UOC, llevat que els propietaris dels drets intel·lectuals donin la seva autorització explícita

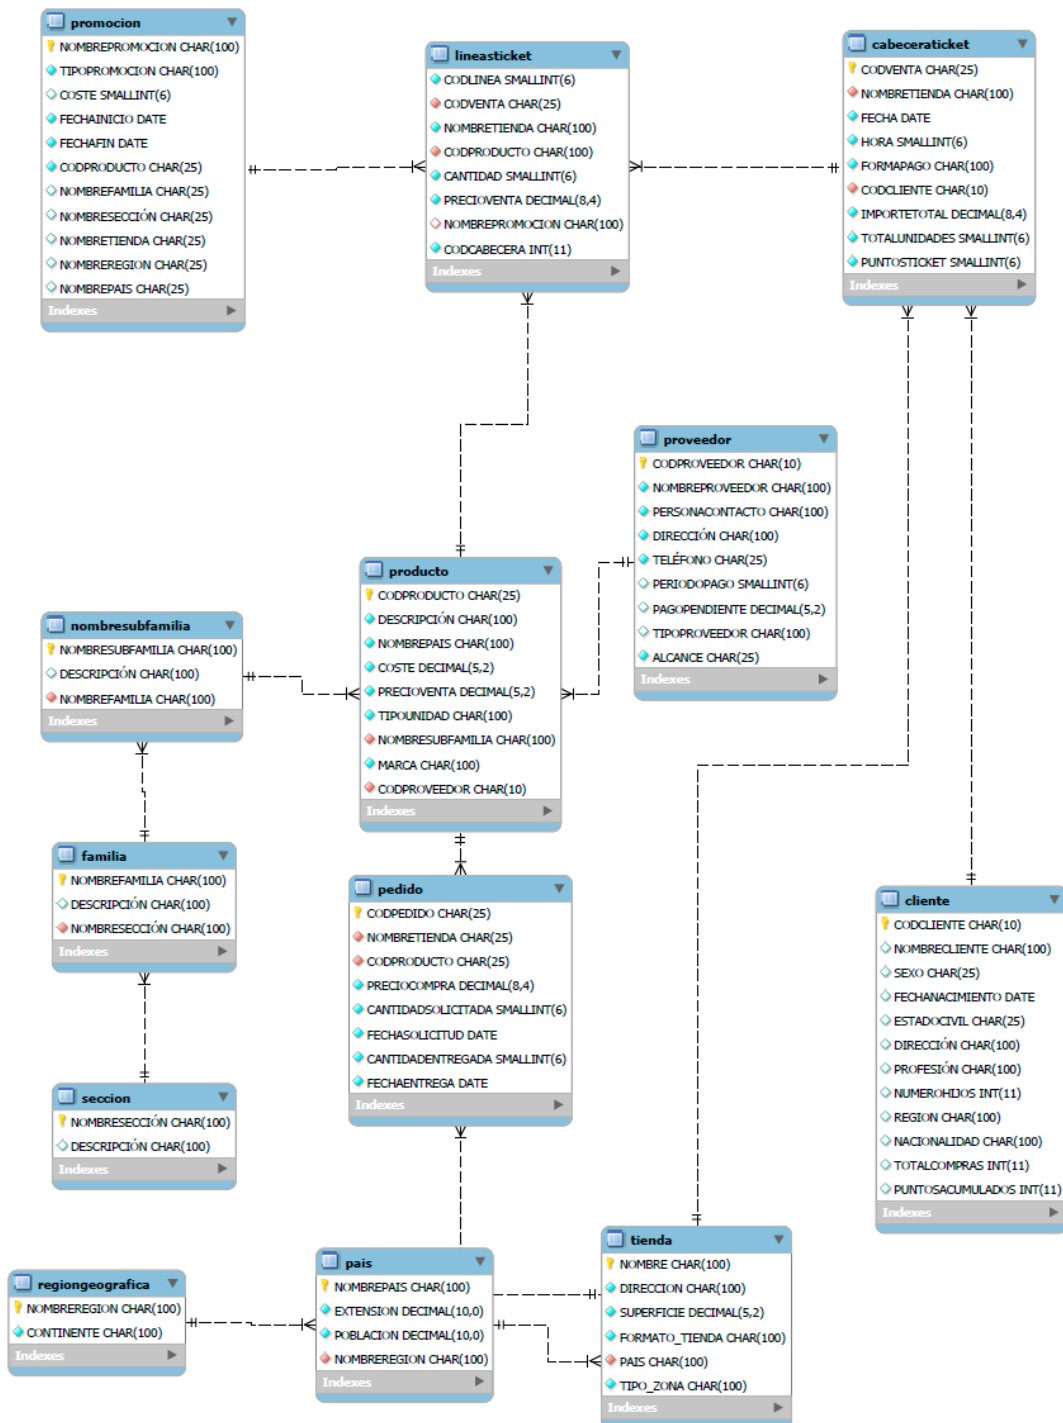



Introducció

Aquesta pràctica tracta de plantejar com podria ser un projecte real de mineria de dades. Com a analistes de dades a partir de la presentació del client que exposa un problema de negoci difús i molt genèric haurem de reconduir-lo com a projecte de mineria de dades.

El client ens proporciona un conjunt de dades extretes del seu ERP, format per les següent taules: `cabeceraticket`, `client`, `familia`, `lineasticket`, `pais`, `pedido`, `producto`, `promocion`, `proveedor`, `regiongeografica`, `seccion`, `subfamilia`, `tienda`.

Tot seguit es mostra el diagrama EER de la base de dades `gourmetDB`:



EER-GourmetDB



Els objectius principals del projecte de mineria de dades seran els següents:

En primer lloc, com què tenim poca informació del domini i volem començar a tenir-ne una idea més clara, intentarem **trobar similituds i agrupar objectes semblants**.

En segon lloc, a partir de la situació més informada obtinguda en el pas anterior, tractarem de **classificar els objectes**. El que es vol és estudiar millor les diferències entre grups i les seves característiques peculiars.

PRIMER OBJECTIU

Trobar grups de clients semblants.

SEGON OBJECTIU

Un cop separats els clients en diversos grups, volem saber quin és l'atribut que distingeix millor un grup de clients o l'altre.



PART I Preparació de les Dades

Pre-processament de les Dades

Carrega i exàmen preliminar del conjunt de dades

En primer lloc, instal·larem el paquet `readr`⁴ que forma part del ecosistema `tidyverse`⁵ i que ens permetrà llegir les dades:

```
# La forma més sencilla de instal·lar readr es instal·lar tidyverse
install.packages("tidyverse")

# Alternativament, podem instal·lar només readr
install.packages("readr")
```

Un cop instal·lat el paquet el carregarem a la sessió R mitjançant la següent línia de codi:

```
# Carrega de readr
library(readr)

# Alternativament, com que forma part de tidyverse
library(tidyverse)
```

⁴ Paquet per a la lectura de dades amb format rectangular: <https://readr.tidyverse.org/>

⁵ Conjunt de paquets R per a la Ciència de les Dades :<https://www.tidyverse.org/>



Observem que, hem fet ús de la segona opció que carrega tots els paquets de `tidyverse`, ja que utilitzarem per a la realització de la pràctica altres paquets, com per exemple: `dplyr` (per a la transformació de dades), `tibble` (per a un tractament més refinat de `data.frames`), `ggplot2` (per a la visualització de les dades), etc.


Un cop carregat el paquet a la sessió R, ja podem fer ús de les funcions. Per a importar les dades dels clients i els seus tickets de compra utilitzarem la funció `read_csv()` de la següent manera:

```
# Carreguem la llibreria que ens permet importar arxius CSV
if (!require("readr")) {
  # Instal·lació de la llibreria
  install.packages("readr")
# Carreguem la llibreria
library(readr)
}
client <- read_csv("data/gourmetdb/cliente.csv",
                  col_names = FALSE)
ticket <- library(readr)
ticket <- read_csv("data/gourmetdb/cabeceraticket.csv",
                  col_names = FALSE)
```

Convertim el conjunt de dades `client` que és del tipus `data.frame` a `tibble`:

```
# Convertim el dataframe a tibble
as_tibble(client)

## # A tibble: 4,069 x 12
##   X1      X2      X3      X4 X5      X6      X7      X8 X9      X10     X11
##   <chr> <chr> <chr> <int> <chr> <chr> <chr> <int> <chr> <ch> <int> <
## 1 0000~ Roca~ Homb~ 1.96e7 Solt~ Piaza~ Econ~ 0 Sur ~ Esp~ 4
## 2 0065~ Fuen~ Mujer 1.94e7 Casa~ C/ N~ Inge~ 1 Sur ~ Esp~ 16
## 3 0065~ Prat~ Homb~ 1.94e7 Casa~ cors~ Doct~ 2 Sur ~ Esp~ 14
## 4 0000~ Jone~ Homb~ 1.91e7 Solt~ 1 Pl~ Inge~ 0 Nort~ Rei~ 2
```

```
9
## 5 0000~ Burt~ Homb~ 1.94e7 Casa~ 46 S~ Doct~ 2 Nort~ Rei~ 13
9
## 6 0065~ Sale~ Mujer 1.94e7 Casa~ Leop~ Econ~ 1 Nort~ Rei~ 7
11
## 7 0065~ Crui~ Homb~ 1.96e7 Solt~ 2 Re~ Inge~ 0 Nort~ Rei~ 10
12
## 8 0131~ Cole~ Homb~ 1.94e7 Casa~ 67 E~ Doct~ 0 Nort~ Est~ 2
6
## 9 0131~ Shav~ Mujer 1.96e7 Casa~ 432 ~ Econ~ 3 Nort~ Est~ 21
15
## 10 0196~ Mill~ Homb~ 1.94e7 Divo~ 68 A~ Econ~ 0 Nort~ Rei~ 5
9
## # ... with 4,059 more rows
```

Podem adonar-nos que, el conjunt de dades està format per 4.069 observacions i 12 variables. A més, amb l'ajuda de [tibble](#) també podem observar el tipus per a cada columna.

Com que el nom de les columnes es poc descriptiu per alguns dels atributs, personalitzarem els noms mitjançant la següent línia de codi:

```
# Noms dels atributs
names(client) <- c("CODCLIENT", "NOMCLIENT", "GENERE", "DATANAIXEMENT", "
ESTATCIVIL",
                  "DIRECCIO", "PROFESSIO", "NROFILLS", "REGIO",
                  "NACIONALITAT", "TOTALCOMPRES", "PUNTSACUMULATS")
names(ticket) <- c("CODVENTA", "NOMTENDA", "DATA", "HORA", "FORMAPAGAMENT
",
                  "CODCLIENT", "TOTALIMPORT", "TOTALUNITATS", "PUNTSTICK
ET")
```

Podem comprovar el nom de les columnes mitjançant la funció [colnames](#):

```
# Comprovem es nom de les columnes
colnames(client)

## [1] "CODCLIENT" "NOMCLIENT" "GENERE" "DATANAIXEMENT"
"
```



```
## [5] "ESTATCIVIL"      "DIRECCIO"        "PROFESSIO"       "NROFILLS"
## [9] "REGIO"          "NACIONALITAT"    "TOTALCOMPRES"    "PUNTSACUMULAT
S"

# Comprovem es nom de les columnes
colnames(ticket)

## [1] "CODVENTA"      "NOMTENDA"        "DATA"            "HORA"
## [5] "FORMAPAGAMENT" "CODCLIENT"       "TOTALIMPORT"     "TOTALUNITATS"
## [9] "PUNTSTICKET"
```

Exploració i Tractament de Valors Desconeguts

Per altra banda, ens caldria comprovar que el nostre conjunt de dades no conté valors desconeguts. En primer lloc comprovem el conjunt de dades client:

```
# Estadístiques de valors buits client
colSums(is.na(client))

##      CODCLIENT      NOMCLIENT      GERE      DATANAIXEMENT      ESTATC
IVIL
##           0           0           0           0
805
##      DIRECCIO      PROFESSIO      NROFILLS      REGIO      NACIONAL
ITAT
##           0           0           805           0
0
##      TOTALCOMPRES PUNTSACUMULATS
##           0           0
```

Com es pot observar la variable `estatcivil` conté 805 observacions amb valors desconeguts. Amb l'objectiu de fer aquest grup més descriptiu podríem canviar aquests valors per la constant `Desconegut`:



```
# Amb l'ajuda de un test lògic descobrim els valors desconeguts
missing_values_estat_civil <- is.na(client$ESTATCIVIL)
# Reemplacem els valors desconeguts amb la constant
client$ESTATCIVIL[missing_values_estat_civil] <- "Desconegut"
```

A més, fixe-mos que la variable `nombrefills` també conté 805 observacions amb valors desconeguts. En aquest cas, reemplaçarem els valor desconeguts amb un valor aleatori de la distribució de la variable. Em primer lloc, amb l'ajuda d'un test lògic descobrim els valors desconeguts:

```
# Amb l'ajuda de un test lògic descobrim els valors desconeguts
missing_values_nombrefills <- is.na(client$NROFILLS)
```

A continuació, generem un valor aleatori de la distribució de la variable:

```
# Generem observacions aleatòries
random_nombrefills_obs <- sample(na.omit(client$NROFILLS), 1)
random_nombrefills_obs

## [1] 3
```

Finalment, reemplaçem els valors desconeguts amb el valor aleatori calculat en en fragment de codi anterior:

```
# Reemplacem els valors desconeguts amb la observació aleatòria
client$NROFILLS[missing_values_nombrefills] <- random_nombrefills_obs
```

Pel que fa al conjunt de dades `ticket` realitzarem les mateixes tasques que hem realitzat amb els clients. Així començarem comprovant que no tinguem dades desconegudes:



```
# Estadístiques de valors buits tickets
```

```
colSums(is.na(ticket))
```

##	CODVENTA	NOMTENDA	DATA	HORA	FORMAPAGAMENT
##	0	0	0	0	0
##	CODCLIENT	TOTALIMPORT	TOTALUNITATS	PUNTSTICKET	
##	38810	0	0	0	

Com es pot comprovar a l' anterior fragment de codi el conjunt de dades `ticket` conté 38810 observacions amb valors desconeguts per a la variable `CODCLIENT`.

Aquest camp segons el model relacional de la base de dades correspon a la clau forana que relaciona amb la taula `cliente`.

Com a conseqüència, les observacions de la taula `cabeceraticket` que contenen un valor desconegut no poden ser combinades amb la taula `clientes`, per això les eliminarem del conjunt de dades:

```
# Carreguem la llibreria que ens permet importar arxius CSV
```

```
if (!require("tidyverse")) {
```

```
  # Instal·lació de la llibreria
```

```
install.packages("tidyverse")
```

```
# Carreguem la llibreria
```

```
library(tidyverse)
```

```
}
```

```
# Filtrem les observacions que contenen NA per a la variable CODCLIENT
```

```
# i modifiquem la taula ticket amb el resultat
```

```
ticket <- ticket %>% filter(!is.na(ticket$CODCLIENT))
```



Transformació d'atributs

L'objectiu principal d'aquest apartat es realitzar tasques de transformació en les variables del nostre conjunt de dades.

Per a facilitar l'anàlisi seria convenient canviar els atributs de tipus `character` a `factor`, que és la manera que té R de tractar amb les variables de tipus categòric:

```
# Carreguem ecosistema tidyverse
if (!require("tidyverse")) {
  # Instal·lació de la llibreria
  install.packages("tidyverse")
# Carreguem la llibreria
library(tidyverse)
}
# Canviem les variables de tipus `character` a `factor`
cols <- c('CODCLIENT', 'NOMCLIENT', 'GENERE', 'ESTATCIVIL', 'DIRECCIO',
          'PROFESSIO', 'REGIO', 'NACIONALITAT')
client <- mutate_at(client, cols, as.factor)
```

De la mateixa manera, ens caldrà fer igual amb les variables de tipus `character` en el conjunt de dades `ticket`:

```
# Canviem les variables de tipus `character` a `factor`
cols <- c('CODVENTA', 'NOMTENDA', 'FORMAPAGAMENT', 'CODCLIENT')
ticket <- mutate_at(ticket, cols, as.factor)
```

Fixe-mos amb el codi anterior que amb l'ajuda de la funció `dplyr::mutate_at`⁶ hem canviat les columnes de tipus `character` al tipus `factor`.

⁶ La notació `paquet::nom_funció` s'utilitza per a indicar a R que es vol fer ús de la funció del paquet indicat, en el cas que existeixi ambigüitat amb el nom d'una funció en un altre paquet.



Amb el següent fragment de codi i amb l'ajuda de la funció `lapply()` verifiquem que s'han produït els canvis. Per exemple, comprovem-ho amb el conjunt de dades `client`:

```
# Retorna el tipus de cada variable
lapply(client, class)
```

```
## $CODCLIENT
## [1] "factor"
##
## $NOMCLIENT
## [1] "factor"
##
## $GENERE
## [1] "factor"
##
## $DATANAIXEMENT
## [1] "integer"
##
## $ESTATCIVIL
## [1] "factor"
##
## $DIRECCIO
## [1] "factor"
##
## $PROFESSIO
## [1] "factor"
##
## $NROFILLS
## [1] "integer"
##
## $REGIO
## [1] "factor"
##
## $NACIONALITAT
## [1] "factor"
##
## $TOTALCOMPRES
## [1] "integer"
##
## $PUNTSACUMULATS
## [1] "integer"
```



Cal fer esment específic que seria pràctic convertir la variable `DATANAIXEMENT` del tipus `numeric` a `date`:

```
# Carreguem lubridate per al tractament de dades de tipus date
if (!require("lubridate")) {
  # Instal·lació de la llibreria
  install.packages("lubridate")
# Carreguem la llibreria
library(lubridate)
}
# Convertim la variable naixement a tipus date
client <- client %>% mutate_at("DATANAIXEMENT", funs(ymd))
```

edat

Gràcies a l'anterior canvi de tipus podem calcular la edat del client i crear una nova columna que anomenarem `EDAT` amb el valor calculat de la següent manera:

```
# Carreguem ecosistema tidyverse
if (!require("tidyverse")) {
  # Instal·lació de la llibreria
  install.packages("tidyverse")
# Carreguem la llibreria
library(tidyverse)
}
client <- client %>%
  mutate(EDAT = year(Sys.Date()) - year(client$DATANAIXEMENT))
```

De forma semblant, canviem la variable `DATA` del conjunt de dades `ticket` a tipus `date`:

```
# Carreguem lubridate per al tractament de dades de tipus date
if (!require("lubridate")) {
  # Instal·lació de la llibreria
  install.packages("lubridate")
# Carreguem la llibreria
library(lubridate)
}
```



```
# Convertim la variable naixement a tipus date
ticket <- ticket %>% mutate_at("DATA", funs(ymd))
```

En un altre ordre de coses, crearem un nou conjunt de dades que es tractarà de la consulta **left-join** de les taules **client** i **ticket** que estan relacionades a la fase de dades per la clau forana **CODCLIENT**:

```
# Selecciona les observacions que apareixen almenys en una de les taules
# cpnervant totes les observacions de ticket
tickets_client <- left_join(client, ticket, by = "CODCLIENT")
```

A continuació, crearem una nova columna amb la suma dels imports totals dels tickets per a cada client. Es a dir, agruparem les observacions per client i calcularem una nova variable amb la funció d'agregació **sum()**:

```
# Agrupem per client i realitzem la suma del import de cada ticket
import_total_tickets_client <- tickets_client %>%
  group_by(CODCLIENT) %>%
  summarise(TOTAL = sum(TOTALIMPORT))
```

Amb el següent fragment de codi afegim la variable creada anteriorment al conjunt de dades **tickets_client**:

```
tickets_client <- tickets_client %>% select(-CODVENTA, -DATA,
                                           -HORA, -FORMAPAGAMENT,
                                           -TOTALIMPORT, -TOTALUNITATS,
                                           -PUNTSTICKET) %>%
  group_by(CODCLIENT) %>%
  na.omit(.) %>%
  distinct(.) %>%
  left_join(import_total_tickets_client,
            by = "CODCLIENT")
```




Identificació d'Etiquetes Errònies en Variables Categòriques

En aquest apartat analitzarem les diferents etiquetes per a les variables categòriques. En concret estudiarem la variable **GENERE** que presenta les següents etiquetes:

```
tickets_client %>% group_by(GENERE) %>%  
  count()  
  
## # A tibble: 3 x 2  
## # Groups:   GENERE [3]  
##   GENERE      n  
##   <fct>   <int>  
## 1 Empresa    781  
## 2 Hombre   2002  
## 3 Mujer    1140
```

Prenent en consideració, que des de el nostre criteri la categoria **empresa** hauria de ser representada mitjançant un altra entitat a la base de dades, decidim eliminar les observacions:

```
# Filtrem observacions on el valor en atribut `GENERE` es igual `empresa`  
i  
# les descartem del conjunt de dades  
tickets_client <- tickets_client %>%  
  filter(GENERE != "Empresa")
```

Per altra banda, observem que la variable **PROFESSIO** conté 10 classes:

```
levels(tickets_client$PROFESSIO)  
  
## [1] "Alimentación"  
## [2] "Ama de Casa"  
## [3] "Architectos,Decoradores & Humanistas"  
## [4] "Catering"  
## [5] "Doctores & Profesionales de la Salud"
```



```
## [6] "Economistas,Abogados & Admin.Empresas"  
## [7] "Food"  
## [8] "Gerentes & Directivos"  
## [9] "Ingenieros & Especialistas"  
## [10] "Servicios"
```

Amb la intenció de simplificar el nostre model, reduïrem el nombre de classes i agruparem **Food**, **Catering** i **Alimentación** en una sola variable atès que sembla que representen una mateixa categoria:



```
# Carreguem forcats  
if (!require("forcats")) {  
  # Instal·lació de la llibreria  
  install.packages("forcats")  
  # Carreguem la llibreria  
  library(forcats)  
}  
# Combinem les classes  
tickets_client$PROFESSIO<- fct_collapse(tickets_client$PROFESSIO,  
  Alimentacion = c("Alimentación", "Food", "Catering")  
)
```

Identificació de *outliers*

En aquest apartat identificarem els valors atípics (en anglès, *outliers*). La identificació dels valors atípics és important perquè poden representar errors en l'entrada de dades. A més, encara que el outlier sigui una dada vàlida, certs mètodes estadístics són sensibles a la presència de valors extrems.

Per a identificar els outliers de dades numèriques podem realitzar el *histograma* de la variable. Tot seguit, es mostra el histograma del total de compres del nostre conjunt de dades.

```
tickets_client %>% ggplot(mapping = aes(x=TOTALCOMPRES)) +  
  geom_histogram(binwidth = 1, aes(fill = ..count..) )
```



Podem observar que existeixen un grup de valors solitaris al extrem dret de la cola de la distribució. Amb la finalitat de comprovar que es tracten de un valors atípics farem ús del mètode del *rang interquartilic* (IQR) o sigui, calcularem la diferència entre el tercer quartil (Q3) i el primer (Q1):

```
# Calculem els quantils
quantile(tickets_client$TOTALCOMPRES)

##      0%    25%    50%    75%   100%
##      1      4      7    11    33

# Calculem el rang interquartilic
IQR(tickets_client$TOTALCOMPRES)

## [1] 7
```

Si considerem que un valor és atípic quan es compleix que:

a) és menor que $Q1 - 1.5(IQR)$ o,



b) és major que $Q3 + 1.5(IQR)$

LLavors tenim que en el conjunt de dades `tickets_client` existeixen 42 valors extrems:

```
Q1 <- 4
Q3 <- 11
IQR <- 7
tickets_client <- tickets_client %>%
  mutate(OUTLIER = case_when(TOTALCOMPRES < Q1 - 1.5*IQR ~ "OUTLIER",
                             TOTALCOMPRES > Q3 + 1.5*IQR ~ "OUTLIER",
                             TRUE ~ as.character(TOTALCOMPRES)))

table(tickets_client$OUTLIER)
```

##	1	10	11	12	13	14	15	16	1
7									
##	132	190	156	135	122	87	66	71	3
8									
##	18	19	2	20	21	3	4	5	
6									
##	33	31	167	27	15	250	262	287	28
6									
##	7	8	9	OUTLIER					
##	279	239	210	59					


Prenent en consideració aquests resultats i per tal que els resultats dels nostres models no es vegin afectats, filtrarem aquestes observacions i les eliminarem del conjunt de dades `tickets_client`:

```
# Filtrarem per valors no atípics
tickets_client <- tickets_client %>% filter(OUTLIER != "OUTLIER")
tickets_client$OUTLIER <- NULL
```



A continuació, analitzarem la distribució de la variable **EDAT** del conjunt de dades **client**:

```
tickets_client %>% ggplot(mapping = aes(x=EDAT)) +  
  geom_histogram(binwidth = 5, aes(fill = ..count..) )
```



Com es pot observar en el gràfic existeixen valors per damunt de 100 anys. Podem comprovar-ho amb la següent línia de codi:

```
# Rang variable edat  
range(client$EDAT)  
## [1] 40 109
```

Fixe-mos que el rang està comprés entre 40 i 109 anys, sembla que la edat estigui mal calculada. Si analitzem com hem calculat la **edat** anteriorment podem comprovar que



els calculs són correctes, ja que hem realitzat la diferència de la data actual amb la data de naixement.

En conseqüència, ens fa pensar que el conjunt de dades de la base de dades [GourmetBD](#) està format per valors pretèrits. Podem comprobar-ho obtenint la data de compra del conjunt de dades [tickets](#):

```
# Obtenim l'any dels tickets
table(year(ticket$DATA))

##
## 2000
## 35517
```

Per aquest motiu, anem a calcular de nou la variable [EDAT](#) però en aquest cas utilitzarem com a any en curs el 2000:

```
# Calculem la edat client utilitzant com a any en curs 1992
client <- client %>%
  mutate(EDAT = 2000 - year(client$DATANAIXEMENT))
```

Concretament, després de realitzar els nous calculs podem comprovar que el rang està entre 21 i 90:

```
range(client$EDAT)

## [1] 21 90
```

Transformació de les Dades

Per a la *normalització* del conjunt de dades [tickets_client](#) utilitzarem el **mètode d'estandardització de valors** assegurant-nos que s'obtenen valors dins el rang escollit que tenen la propietat que la seva mitjana és zero i la seva desviació estàndard val 1.



Es a dir, l'estandardització consisteix en la diferència entre el valor de l'atribut i la seva mitjana, dividint aquesta diferència per la desviació estàndard dels valors de l'atribut. Es a dir:

$$Z - score = \frac{X - mean(X)}{SD(X)}$$

En el següent fragment discretitzarem les variables **NROFILLS**, **PUNTSACUMULATS**, **EDAT** i **TOTAL** estandaritzant-les amb l'ajuda de la funció `scale()`:

```
tickets_client <- tickets_client %>% mutate_at(vars(NROFILLS, TOTALCOMPRES,
PUNTSACUMULATS, EDAT,
TOTAL),
funs(scale(.)))
```

A banda d'això, per a facilitar el nostre anàlisi, realitzarem una segmentació dels nostres clients respecte la freqüència de compra.

Així, realitzarem una discretització utilitzant l'atribut **TOTALCOMPRES** que pren els valors entre 1 i 21 dividint els valors entre els conjunts: **FREQÜENT**, **HABITUAL** i **OCASIONAL**.

1. **Clients freqüents:** és molt important cuidar molt especialment als clients de compra freqüent i donar-los un tracte preferencial que els faci sentir-se valorats i mantenir d'aquesta forma el seu nivell de compres.
2. **Clients habituals:** aquests clients convé mantenir-los amb un excel·lent nivell de satisfacció generant activitats que propiciïn un augment en la freqüència.
3. **Clients ocasionals:** si bé és cert que els clients ocasionals mereixen rebre un bon servei com tot client, el nivell d'inversió i atenció a destinar, serà menor que el subministrat als clients més rendibles per a la companyia.

En primer lloc, hem de calcular la distribució de freqüències absolutes de la variable **TOTALCOMPRES**:



```
total_compres <- tickets_client$TOTALCOMPRES
breaks <- seq(1, 21, by = 5)
total_compres_cut <- cut(total_compres, breaks, by = 5, right = FALSE)
total_compres_freq <- table(total_compres_cut)
```

Amb la funció `nrow()` podem trobar la freqüència total n del conjunt de dades, així podem realitzar el cocient de les freqüències absolutes per n . De manera que, la **distribució de freqüències relatives** es:

```
# Càlcul distribució freqüències relatives total compres per client
total_compres_relfreq <- total_compres_freq / nrow(tickets_client)
cbind(total_compres_freq, total_compres_relfreq)

##           total_compres_freq total_compres_relfreq
## [1,6)                1098             0.35614661
## [6,11)               1204             0.39052871
## [11,16)              566             0.18358741
## [16,21)              200             0.06487188
```

Finalment, creem una nova variable que classificarà els nostres clients segons la freqüència de compra:

```
tickets_client <- tickets_client %>%
  mutate(FREQCOMPRA = case_when(between(TOTALCOMPRES, 1, 6) ~ "OCCASIONAL",
                                between(TOTALCOMPRES, 7, 16) ~ "FREQUENT",
                                between(TOTALCOMPRES, 17, 21) ~ "HABITUAL" ))

# Canviem la variable de tipus `character` a `factor`
tickets_client$FREQCOMPRA <- as.factor(tickets_client$FREQCOMPRA)
```

Per altra banda, classificarem els nostres clients segons el **volum de ventes**. Per a poder realitzar aquesta classificació, cal partir de la premissa del 80/20, és a dir, el 80% de les teves ventes les realitzen el 20% dels teus clients. En funció d'això, els classificariem de la següent manera:



1. **Clients Top:** són aquells clients que generen un volum de vendes molt per sobre de la mitjana. Cal fer esment específic que conèixer perfectament aquest grup de clients, ens permetrà definir els nostres esforços i recursos.
2. **Clients Grans:** clients que generen un volum de vendes mig-alt. Són importants, però no representen el volum dels Top.
3. **Clients Mitjans:** es tracta del clients que generen un volum de vendes mitja.
4. **Clients Baixos:** són aquells les vendes dels quals estan molt per sota de la mitjana.

En primer lloc, calculem un resúm estadístic de la variable **TOTAL** per tal de coneixer la mitjana de compres dels nostres clients:

```
summary(tickets_client$TOTAL)
```

##	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
##	3.425	95.744	188.915	287.960	370.529	2671.198

Finalment, creem una nova variable que classificarà els nostres clients segons el volúm de venda:

```
tickets_client <- tickets_client %>%  
  mutate(VOLUMVENTA = case_when(between(TOTAL, 1, 95) ~ "BAIX",  
    between(TOTAL, 95, 370) ~ "MITJA",  
    between(TOTAL, 370, 3000) ~ "ALT" ))  
  
# Canviem la variable de tipus `character` a `factor`  
tickets_client$FREQCOMPRA <- as.factor(tickets_client$VOLUMVENTA)
```

Reducció de la Dimensionalitat

Per a la simplificació de l'anàlisi les següents variables són descartades:



```
# Reducció de la dimensionalitat
#tickets_client$CODCLIENT <- NULL
tickets_client$NOMCLIENT <- NULL
tickets_client$DIRECCIO <- NULL
tickets_client$DATANAIXEMENT <- NULL
#tickets_client$REGIO <- NULL
```

Els motius són els següents:

- La variable **CODI** representa la clau primària en la base de dades i no ens proporcionarà informació per a estudiar millor les diferències entre grups.
- La variable **NOM** pot ser eliminada pel fet que, es tracta del nom del individu i que té funcions de particularització o individualització i no ens serveix per a les tasques d'agrupació i classificació.
- La variable **DIRECCIO** es tracta de la direcció del domicili del client i no ens proporciona informació rellevant per a la nostra anàlisi.
- La variable **DATANAIXEMENT** pot ser eliminada, ja que representa la data de naixement del client i no proporciona informació per al nostre model. No obstant, l'edat del client és una característica peculiar i es pot estimar a partir de la data de naixement i la data actual. Aquest atribut ja ha sigut calculat i representat amb la variable **EDAT**.
- Per últim, també eliminarem les variables de **REGIO** perquè tan sols tenim 15 botigues, repartides en 2 continents i l'extrapolació de resultats a zones geogràfiques seria immediata i trivial.

Recollint tot el que s'ha realitzat, tenim 10 atributs per a la nostra anàlisi i 3083 observacions en el conjunt de dades **client**:

```
# Obtenim el nom de les variables
colnames(tickets_client)
```

##	[1]	"CODCLIENT"	"GENERE"	"ESTATCIVIL"	"PROFESSIO"
##	[5]	"NROFILLS"	"REGIO"	"NACIONALITAT"	"TOTALCOMPRES"



```
## [9] "PUNTSACUMULATS" "EDAT" "NOMTENDA" "TOTAL"
## [13] "FRECOMPRA" "VOLUMVENTA"

# Obtenim la dimensió
dim(tickets_client)

## [1] 3083 14
```

Anàlisi Exploratori de les Dades

El tema següent tracta de l'ànalisi exploratori de les dades (EDA), o anàlisi gràfic de les dades, EDA ens permetrà:

- Analitzar amb profunditat el conjunt de dades.
- Examinar la relació entre variables.
- Identificar subconjunt d'observacions.





- Desenvolupar una idea d'una possible associació entre les variables predictores (independents) així com, entre les predictores i la variable de resposta (dependent).

En primer lloc, passem a estudiar la variable `GENERE` respecte a `FREQCOMPRA`. Per tal d'explorar la relació entre aquestes variables realitzarem les següents operacions:

- Agrupar el conjunt de dades per la variable `GENERE`.
- Contar el nombre d'observacions de la variable `FREQCOMPRA` que apareixen en cada classe del atribut `GENERE`.
- Calcular el percentatge en cada classe segons la variable `FREQCOMPRA`.

Totes aquestes operacions queden simplificades amb l'ajuda de les funcions `group_by` i `count` del paquet `dplyr`, i de l'operador `%>%`:

```
# Gràfic barra genere vs freqüència de compra
tickets_client %>%
  group_by(GENERE) %>%
  count(FREQCOMPRA) %>%
  mutate(freq = round(n / sum(n) * 100, 0)) %>%
  ggplot(mapping = aes(y = n, x = GENERE, color=FREQCOMPRA, fill=FREQCOMPRA)) +
  geom_bar(stat="identity") +
  geom_text(aes(label = paste(freq, "%")), color="black") +
  facet_wrap(~FREQCOMPRA)
```



És a saber, que obtenim els mateixos resultats que al gràfic anterior però en format de resúm amb el següent codi:

```
# Resúm de les dades
tickets_client %>%
  group_by(GENERE) %>%
  count(FRECOMPRA) %>%
  mutate(FREQ = round(n / sum(n) * 100, 0)) %>%
  arrange(desc(FREQ))


## # A tibble: 6 x 4
## # Groups:   GENE [2]
##   GENE FRECOMPRA    n FREQ
##   <fct> <fct>    <int> <dbl>
## 1 Mujer MITJA     566   51
## 2 Hombre MITJA    980   50
## 3 Hombre ALT      498   25
## 4 Hombre BAIX     489   25
```



```
## 5 Mujer ALT 274 25
## 6 Mujer BAIX 276 25
```

En segon lloc, estudiarem la variable **ESTATCIVIL**. Realitzant els mateixos passos que en el apartat anterior obtenim el següent diagrama de barres:


```
# Gràfic barra estat civil vs freqüència de compra
tickets_client %>%
  group_by(ESTATCIVIL) %>%
  count(FREQCOMPRA) %>%
  mutate(freq = round(n / sum(n) * 100, 0)) %>%
  ggplot(mapping = aes(x = ESTATCIVIL, y = n, fill = FREQCOMPRA)) +
  geom_bar(stat = "identity") +
  geom_text(aes(label = paste(freq, "%"))) +
  theme(axis.text.x = element_text(size = 12, angle=90)) +
  facet_wrap(~FREQCOMPRA)
```





Prosseguim el nostre anàlisi amb la variable **PROFESSIO**. Igual com hem fet anteriorment obtenim el següent diagrama de barres:


```
# Gràfic barra professió vs freqüència de compra
tickets_client %>%
  group_by(PROFESSIO) %>%
  count(FREQCOMPRA) %>%
  mutate(freq = round(n / sum(n) * 100, 0)) %>%
  ggplot(mapping = aes(x = PROFESSIO, y = n, fill = FREQCOMPRA)) +
  geom_bar(stat = "identity") +
  geom_text(aes(label = paste(freq, "%"))) +
  theme(axis.text.x = element_text(size = 14, angle=90)) +
  facet_wrap(~FREQCOMPRA)
```





Avançant en el nostre anàlisi exploratori , passem a examinar el percentatge de variació entre les variables **REGIO** i **FREQCOMPRA**:


```
# Gràfic barra regio vs freqüència de compra
tickets_client %>%
  group_by(REGIO) %>%
  count(FREQCOMPRA) %>%
  mutate(freq = round(n / sum(n) * 100, 0)) %>%
  ggplot(mapping = aes(x = REGIO, y = n, fill = FREQCOMPRA)) +
  geom_bar(stat = "identity") +
  geom_text(aes(label = paste(freq, "%"))) +
  theme(axis.text.x = element_text (size = 14, angle=45)) +
  facet_wrap(~FREQCOMPRA)
```






Per acabar, analitzem la variable **NACIONALITAT**. El següent fragment de codi ens mostra una representació gràfica en diagrama de barres de la variable respecte a **FREQCOMPRA**:

```
# Gràfic barra regio vs freqüència de compra
tickets_client %>%
  group_by(NACIONALITAT) %>%
  count(FREQCOMPRA) %>%
  mutate(freq = round(n / sum(n) * 100, 0)) %>%
  ggplot(mapping = aes(x = NACIONALITAT, y = n, fill = FREQCOMPRA)) +
  geom_bar(stat = "identity") +
  geom_text(aes(label = paste(freq, "%"))) +
  theme(axis.text.x = element_text(size = 14, angle=45)) +
  facet_wrap(~FREQCOMPRA)
```




Recapitulant, després d'haver realitzat l'ànalisi de les diferents variables només hem escollit com a descriptors per al nostre model les que se mostren a continuació:



```
# Resúm de `tickets-client`
summary(tickets_client)

##      CODCLIENT      GENERE      ESTATCIVIL
## Length:3083      Empresa:  0      Casado/a      :1238
## Class :character      Hombre :1967      Desconegut   :  0
## Mode  :character      Mujer  :1116      Divorciado/a: 614
##                                           Soltero/a    :1155
##                                           Viudo/a      :  76
##
##
##
##                                PROFESSIO      NROFILLS
## Economistas,Abogados & Admin.Empresas:663      Min.      :0.0000
## Gerentes & Directivos                      :656      1st Qu.:0.0000
## Doctores & Profesionales de la Salud :633      Median :0.0000
## Ingenieros & Especialistas              :480      Mean   :0.9676
## Arquitectos,Decoradores & Humanistas :462      3rd Qu.:2.0000
## Ama de Casa                            :189      Max.   :4.0000
## (Other)                                :  0
##
##      REGIO      NACIONALITAT      TOTALCOMPRES
## Norte Europa:1356      España      :1038      Min.      : 1.000
## Norteamérica: 689      Estados Unidos: 689      1st Qu.: 4.000
## Sur Europa  :1038      Reino Unido  :1356      Median : 7.000
##                                           Mean      : 7.791
##                                           3rd Qu.:11.000
##                                           Max.      :21.000
##
##
##      PUNTSACUMULATS      EDAT      NONTENDA      TOTAL
## Min.      : 5.000      Min.      : 40.00      Londres I : 371      Min.      : 3.425
## 1st Qu.: 7.000      1st Qu.: 51.00      Manhattan I: 360      1st Qu.: 95.744
## Median : 9.000      Median : 67.00      Londres II : 311      Median : 188.915
## Mean      : 9.455      Mean      : 66.66      Barcelona : 306      Mean      : 287.960
## 3rd Qu.:11.000      3rd Qu.: 79.00      Milán      : 293      3rd Qu.: 370.529
## Max.      :36.000      Max.      :109.00      París I    : 233      Max.      :2671.198
##                                           (Other)    :1209
##
##      FREQCOMPRA      VOLUMVENTA
## ALT      : 772      Length:3083
## BAIX     : 765      Class :character
## MITJA:1546      Mode  :character
##
##
```



PART II Clustering

Requisits

Per començar, per a la realització del nostre anàlisi necessitarem els següents paquets:

- `cluster` per a la computació dels algorismes d'agregació.
- `factoextra` per a la visualització de resultats d'agregació i que es fonamenta en el paquet `ggplot2`.⁷
- `clValid` que s'utilitza per a comparar els mètodes d'agregació.
- `clustertend` per avaluar estadísticament de les tendències d'agregació.

El paquet `factoextra` conté funcions per anàlisi de *clustering* i visualització dels resultats:

Funció	Descripció
<code>dist(fviz_dist, get_dist)</code>	Visualització i computació de la matriu de distàncies
<code>get_clust_tendency</code>	Avaluació de la tendència d'agregació
<code>fviz_nbclust(fviz_gap_stat)</code>	Determinació del nombre òptim de clústers
<code>fviz_dend</code>	Visualització de dendrogrames
<code>fviz_cluster</code>	Visualització dels resultats d'agrupament
<code>fviz_mclust</code>	Visualització dels resultats del model d'agrupament
<code>fviz_silhouette</code>	Visualització de la informació de la silueta
<code>hkmeans</code>	K-means jeràrquic
<code>eclust</code>	Visualització de l'anàlisi de agrupament

⁷ Per a més informació: <https://topepo.github.io/caret/index.html>



Podem instal·lar els dos paquets com es mostra en la següent línia de codi:

```
# Instal·lació paquets clustering
install.packages(c("cluster", "factoextra", "clValid", "clustertend"))
```

En acabar, ens caldrà carregar les llibreries a la sessió R:

```
# Carreguem les llibreries
library(cluster)
library(factoextra)
library(clValid)
```

Determinació del nombre de clústers

Per a determinar el nombre de clústers farem ús de la funció `fviz_nbclust()` del paquet `factoextra` que calcula els mètodes **Elbow**, **Silhouette** i **Gap**.

El prototip de la funció es el següent:

```
fviz_nbclust(x, FUNcluster, method = c("silhouette", "wss", "gap_stat"))
```

on els arguments són els següents:

- **x**: matriu o data frame.
- **FUNcluster**: una funció d'agregació. Valors possibles: `kmeans`, `pam`, `clara` i `hcut`.
- **method**: mètode per a determinar el nombre òptim de clústers. Valors possibles: **Elbow**, **Silhouette** i **Gap**

Per al nostre anàlisi de la segmentació dels nostres clients utilitzarem el següent conjunt de prova:



```
set.seed(123)
inTrain <- ungroup(tickets_client) %>%
  sample_frac(0.5, replace = TRUE)
training <- scale(inTrain[, c(8, 10, 12)])
```

A continuació podem comprovar que hem obtingut un conjunt de entrenament de 1542 observacions:

```
dim(training)
## [1] 1542    3
```


Tot seguit, es mostra com determinar el nombre òptim de particions per al mètode *k-means*.

```
# Mètode elbow
fviz_nbclust(training, kmeans, method = "wss") +
  geom_vline(xintercept = 4, linetype = 2) +
  labs(x = "Nombre de particions k",
       y = "Total intra-clúster suma de quadrats",
       title = "Nombre òptim de particions",
       subtitle = "Mètode Elbow") +
  theme_classic() +
  theme(plot.title = element_text(color="#4F81BD", size=14, face="bold"),
        plot.subtitle = element_text(color="#4F81BD", size=14))
```



Nombre òptim de particions

Mètode Elbow



Com podem observar en els gràfics:

- El mètode Elbow ens suggereix 4 clústers.

Així és que, segons aquestes observacions podem considerar $k = 4$ com el nombre òptim de clústers.



Mètode d'agregació *k-means*

A causa de que, l'algoritme *k-means* comença seleccionant un centroides aleatòriament, es recomanable fer ús de la funció `set.seed()` a l'efecte de aconseguir resultats reproduïbles. Així el lector d'aquest document obtindrà els mateixos resultats que es presenten tot seguit.


A continuació es mostra com aplicar l'algoritme *k-means* amb $k = 4$:

```
# Execució k-means amb k = 4
set.seed(123)
kmeansFit <- kmeans(training, 4, nstart = 25)
```

Podem mostrar per pantalla els resultats amb la següent línia de codi:

```
# Mostrem els resultats
print(kmeansFit)

## K-means clustering with 4 clusters of sizes 384, 444, 523, 191
##
## Cluster means:
##   TOTALCOMPRES      EDAT      TOTAL
## 1    0.6242264 -0.5172664  0.2680531
## 2   -0.7480189 -0.8135764 -0.6224497
## 3   -0.4613399  0.9539634 -0.4253453
## 4    1.7471111  0.3190333  2.0727272
##
## Clustering vector:
##   [1] 2 3 1 2 1 2 4 2 3 1 3 4 3 3 1 1 2 3 1 4 1 4 4 4 1 4 2 4 1 3 3 2
##   [35] 3 3 2 3 2 1 3 2 2 1 1 1 3 3 3 1 3 3 4 1 4 2 2 3 1 3 3 1 2 2 3 3
##   [69] 3 3 1 3 3 4 3 1 3 4 3 2 1 3 4 3 1 4 1 4 3 2 2 3 2 2 4 1 2 1 1 4
##   [87] 4 3
```



```
## [103] 2 4 3 4 3 3 3 3 3 3 4 1 1 2 1 3 1 1 1 1 3 1 4 4 4 2 4 4 2 3 3 4
2 1
## [137] 1 2 4 4 1 4 1 2 1 2 2 2 4 3 2 1 4 3 2 3 3 1 2 3 4 1 2 2 1 3 1 2
3 3
## [171] 2 2 3 4 4 4 1 1 1 3 3 2 3 3 1 3 3 2 3 3 2 4 4 1 1 3 4 1 1 2 4 1
4 1
## [205] 3 3 2 2 2 3 2 2 3 4 2 3 3 1 3 3 1 2 3 1 3 1 3 3 1 2 4 1 1 1 3 2
2 3
## [239] 2 2 4 1 3 1 1 2 1 4 3 4 3 1 2 4 1 2 2 2 3 4 3 2 2 2 1 2 2 1 3 1
2 1
## [273] 1 3 2 3 3 3 1 1 2 2 1 1 1 3 2 3 3 2 3 3 2 2 4 1 3 2 3 3 2 4 3 2
2 2
## [307] 3 3 3 3 2 3 1 3 2 3 4 2 1 4 3 3 3 2 3 2 3 2 3 2 4 4 3 2 2 3 2 3
1 2
## [341] 2 1 4 1 3 2 3 3 2 3 1 3 1 3 3 1 1 2 2 3 1 3 2 3 3 1 1 3 3 2 4 2
1 2
## [375] 3 3 2 3 2 2 1 3 3 1 2 4 4 2 1 3 1 2 3 1 1 4 3 1 3 2 2 2 3 3 1 2
4 4
## [409] 1 2 2 1 2 3 1 3 4 4 1 2 2 2 3 4 3 2 3 3 3 3 3 3 3 3 1 3 1 2 1 3
1 2
## [443] 3 2 1 4 1 3 3 3 3 1 4 1 3 4 3 3 2 1 2 3 1 3 1 3 4 2 1 3 3 1 2 2
2 1
## [477] 2 4 4 3 2 3 3 3 1 4 2 2 1 4 2 1 2 1 1 3 3 3 3 1 3 3 4 2 3 4 2 2
2 3
## [511] 3 4 2 1 1 3 1 2 4 3 3 4 1 4 3 4 1 3 3 3 1 3 4 1 3 1 1 3 2 3 3 3
2 3
## [545] 1 1 2 1 2 3 3 4 3 2 1 3 4 1 3 1 2 4 1 2 2 1 1 2 3 2 3 3 1 2 1 1
1 2
## [579] 3 3 3 4 3 2 3 3 1 1 1 2 3 4 2 3 3 2 2 1 4 3 2 1 3 2 3 3 1 2 1 3
1 4
## [613] 2 3 2 4 3 1 2 2 4 3 2 3 3 2 3 3 2 2 2 3 1 2 3 1 3 2 1 4 3 3 2 3
4 3
## [647] 1 2 4 1 1 2 2 1 1 1 3 4 1 4 4 1 1 4 3 3 2 2 1 2 3 3 1 1 3 1 3 1
3 2
## [681] 3 2 2 1 2 1 2 2 3 3 2 2 1 3 2 3 3 3 1 2 3 2 1 3 1 4 2 2 3 1 2 3
3 2
## [715] 2 4 4 2 3 2 2 1 4 2 3 1 2 4 3 4 1 3 3 2 3 3 3 1 1 3 3 2 3 3 3 4
1 2
## [749] 2 3 1 1 2 2 3 3 1 2 2 2 1 3 2 2 3 2 3 2 1 2 2 4 1 3 1 1 2 2 1 1
1 2
## [783] 1 3 3 2 3 2 1 2 2 2 2 4 3 2 2 3 4 3 3 2 2 2 2 1 2 3 3 3 3 3 3 2
2 4
## [817] 2 2 2 2 3 2 2 2 1 1 3 3 1 3 3 4 3 2 2 3 3 1 2 1 1 4 4 3 3 2 2 3
3 2
```




```
## [851] 3 1 3 1 2 3 2 3 3 2 1 1 2 2 4 3 2 4 3 4 3 1 3 2 1 1 4 1 3 4 2 4
3 3
## [885] 3 4 1 3 3 2 1 2 3 2 2 2 3 2 2 3 3 2 2 3 4 4 1 4 1 2 3 3 1 3 3 3
3 2
## [919] 2 3 1 3 2 2 3 2 2 2 1 3 1 3 3 3 1 2 4 2 3 2 3 2 4 4 4 3 2 3 1 1
3 3
## [953] 3 3 1 1 4 3 4 1 3 2 3 3 2 3 1 1 3 1 4 3 3 2 1 4 3 4 3 2 1 3 3 2
2 3
## [987] 3 4 3 1 1 1 3 2 1 2 4 1 2 3 3 3 3 1 1 3 3 1 2 2 3 3 1 3 1 3 3 3
2 1
## [1021] 2 1 1 4 2 2 3 4 3 2 2 2 4 3 1 4 2 3 1 4 2 3 4 3 2 1 1 4 2 4 1 1
3 1
## [1055] 4 1 1 3 2 1 2 1 1 2 4 3 1 3 1 1 3 1 2 3 3 3 1 3 1 1 1 3 3 1 1 2
4 2
## [1089] 3 1 3 2 2 1 2 3 1 2 1 2 3 2 4 2 1 3 3 1 3 3 1 3 3 1 1 1 4 4 1 1
2 3
## [1123] 2 1 3 1 3 1 3 2 2 3 2 4 3 3 1 2 3 3 3 2 1 3 4 3 3 1 1 2 3 1 3 4
3 2
## [1157] 2 1 3 1 3 3 3 4 3 1 2 2 2 2 1 1 2 2 3 4 3 2 3 2 3 1 4 2 3 1 3 3
1 1
## [1191] 3 2 1 2 1 2 3 3 1 3 2 4 1 1 2 1 2 4 2 1 2 1 2 3 2 1 2 2 2 4 2 4
2 2
## [1225] 3 4 4 3 2 1 3 1 1 3 3 3 2 3 1 2 3 4 1 1 3 2 3 3 3 3 1 2 4 3 1 1
4 1
## [1259] 3 4 1 2 2 3 2 2 3 1 1 3 1 1 2 3 1 1 3 3 2 1 2 3 3 1 2 1 2 1 2 1
3 3
## [1293] 3 2 2 2 3 4 3 2 3 2 2 1 1 2 4 1 2 3 2 2 2 2 3 4 3 3 4 3 3 3 2 3
3 4
## [1327] 2 4 1 3 4 4 3 3 4 3 1 2 1 4 3 1 4 3 2 1 2 2 4 3 2 3 2 2 3 2 1 3
4 2
## [1361] 1 2 1 2 1 2 2 1 3 1 2 2 3 1 4 1 1 2 1 1 2 2 3 1 3 2 2 3 4 1 3 2
1 3
## [1395] 2 1 2 3 3 2 1 3 3 3 4 1 2 3 1 3 2 2 2 3 4 1 4 2 2 2 4 4 4 1 2 1
2 3
## [1429] 3 1 3 3 2 3 4 2 1 2 2 3 3 4 3 1 1 3 3 1 1 2 2 1 1 1 2 2 1 2 1 2
3 2
## [1463] 1 4 1 1 4 3 2 3 2 2 2 3 2 2 3 3 2 3 1 3 3 3 3 4 1 2 4 3 3 2 3 3
3 3
## [1497] 2 3 2 3 4 2 2 2 3 1 2 2 1 2 4 3 2 3 3 1 2 2 3 2 3 3 2 3 2 4 1 1
2 1
## [1531] 2 3 3 1 1 1 1 1 3 2 2 2
##
## Within cluster sum of squares by cluster:
## [1] 371.3704 249.1781 460.1227 443.1107
```



```
## (between_SS / total_SS =  67.0 %)  
##  
## Available components:  
##  
## [1] "cluster"      "centers"      "totss"        "withinss"  
## [5] "tot.withinss" "betweenss"    "size"         "iter"  
## [9] "ifault"
```

Podem observar en la sortida el següent:

- Que s'han creat 4 clusters de 191, 384, 444 i 523.
- La mitjana de clústers: una matriu, on les files són el nombre de clúster i les columnes són les variables.
- El vector de particions: un vector d'enters (de 1:k) que indica el clúster on cada observació ha sigut agrupada.

Així mateix, és recomanable realitzar un gràfic amb els resultats del model. Ja sigui, per a escollir el nombre de clústers, ja sigui per a comparar diferents anàlisis.

Una possible opció és visualitzar les dades en un diagrama de dispersió acolorint cada observació d'acord al grup assignat.


El problema és que el nostre conjunt de dades conté més de 2 variables i no és possible representar el model en dues dimensions.

Convé fer ressaltar que, una possible solució és reduir la dimensionalitat fent ús d'un algoritme de reducció del nombre d'atributs, com per exemple **Principal Component Analysis (PCA)**.

En aquest sentit, farem ús de la funció `fviz_cluster()` que ens permetrà visualitzar els clústers i que utilitza PCA quan el nombre de variables és més gran de 2. Passarem com a arguments el resultat del model i el conjunt de dades original:



```
# Visualitzem els clústers
fviz_cluster(kmeansFit, data = training, stand = TRUE,
  geom = "point",
  main = "Gràfic de clústers",
  palette = c("#2E9FDF", "#00AFBB", "#E7B800", "#FC4E07"),
  ellipse.type = "euclid",
  star.plot = TRUE,
  repel = TRUE,
  ggtheme = theme_minimal()) +
theme(legend.position = "bottom",
  plot.title = element_text(color="#4F81BD", size=16, face="bold"))
)
```



Gràfic de clústers



Podem observar en el gràfic que les observacions són representades mitjançant punts i que en el nostre cas s'ha usat PCA. A més, s'han dibuixat el·lipses per tal de diferenciar cada clúster.



PART III Classificació

El paquet Caret

Per a la realització del model predictiu utilitzarem el paquet `caret`⁸ (acrònim per a Classification And Regression Tree). Aquest paquet es un *framework* amb un conjunt de funcions que pretén optimitzar el procés de la creació de models predictius. Aquest paquet conté eines per a:

- Divisió del conjunt de dades.
- Pre-processament de dades.
- Selecció d'atributs.
- *Model tuning*⁹ mitjançant remostreig.
- Estimació de la importància de les variables.

En primer lloc, caldrà instal·lar el paquet des del repositori CRAN:

```
install.packages("caret", dependencies = TRUE)
```

A més, ens caldrà instal·lar els següents paquets:

- El paquet `RWeka` que implementa l'algoritme C4.5.
- El paquet `C50` es tracta d'una implementació més moderna de l'algoritme ID3.
- El paquet `rpart` que implementa el mètode CART.

⁸ Per a més informació: <https://topepo.github.io/caret/index.html>

⁹ Procés que consisteix en optimitzar els paràmetres del model amb l'objectiu que l'algoritme obtingue el millor rendiment.



- El paquet `randomForest` que implementa l'agorisme de "Bosc aleatori"¹⁰.

```
install.packages(c("RWeka", "C50", "rpart", "randomForest"))
```

Un cop instal·lats el paquets el carregarem a la sessió R mitjançant la següent línia de codi:

```
# Carrega de caret
library(caret)
# Carrega C50
library(C50)
```

Separació de dades: Conjunt d'entrenament i prova:

En aquest apartat, dividiren el conjunt de dades en dos subconjunts:

- Conjunt d'entrenament: Un subconjunt per a entrenar el model.
- Conjunt de prova: Un subconjunt per a provar el model entrenat.

L'objectiu en aquesta tasca es dividir el conjunt de dades de la següent manera:




Figura 1. Divisió d'un conjunt de dades en un conjunt d'entrenament i un de prova.

¹⁰ De l'anglès *Random Forest*. Per a més informació :https://es.wikipedia.org/wiki/Random_forest



Cal que ens assegurem que el conjunt de prova reuneixi les següents dos condicions:

- Que sigui prou gran com per generar resultats significatius des del punt de vista estadístic.
- Que sigui representatiu de tot el conjunt de dades. En altres paraules, no triar un conjunt de prova amb característiques diferents al del conjunt d'entrenament.

Si suposem que el conjunt de prova reuneix aquestes dues condicions, el nostre objectiu és crear un model que generalitzi les dades noves de forma correcta. En altres paraules, hem de aconseguir un model que no sobreajusti (en àngles, *overfitting*) les dades d'entrenament.

En primer lloc, eliminarem aquells atributs que no son rellevants per a la nostra classificació:

```
# Eliminem atributs innecessaris
tickets_client$CODCLIENT <- NULL
tickets_client$REGIO <- NULL
tickets_client$TOTALCOMPRES <- NULL
tickets_client$NROFILLS <- NULL
tickets_client$TOTAL <- NULL
tickets_client$PUNTSACUMULATS <- NULL
tickets_client$NOMTENDA <- NULL
tickets_client$FREQCOMPRA <- NULL
```

La funció `createDataPartition` ens permetrà crear els subconjunts de dades. Per exemple, per a crear una divisió de un 80/20% del conjunt de dades `tickets_client`:

```
# Carreguem el paquet
library(caret)
set.seed(1234)
# Creem el conjunt d'entrenament i el de prova
inTrain <- createDataPartition(tickets_client$VOLUMVENTA, p = 0.8, list
= FALSE)
```



```
training <- tickets_client[inTrain, ]
testing <- tickets_client[-inTrain, ]
```

A continuació podem comprovar que hem obtingut un conjunt de entrenament de 2467 observacions:

```
dim(training)
```

```
## [1] 2467    6
```

Classificació amb C50

Tot seguit passem a examinar el nostre conjunt de dades amb l'algorisme de classificació C50. Aquest algorisme es tracta d'una implementació més moderna de l'algorisme ID3. C50 realitza *boosting*¹¹, un meta-algorisme d'aprenentatge automàtic que redueix el biaix i variància.


N'és un bon exemple el fragment de codi següent que utilitza l'algorisme C50 implementat al paquet `C50`:

```
# Execució l'algorisme C50
modelFitC50tree <- train(VOLUMVENTA ~ .,
  method = "C5.0",
  data = training)
```

Tot seguit es mostra la matriu de confusió:

```
# Obtenim la matriu de confusió
summary(modelFitC50tree)
```

¹¹ Informació extreta de <https://es.wikipedia.org/wiki/Boosting>



```
##
## Call:
## (function (x, y, trials = 1, rules = FALSE, weights = NULL, control
## = FALSE, sample = 0, earlyStopping = TRUE, label = "outcome", see
## = 979L))
##
##
## C5.0 [Release 2.07 GPL Edition]      Mon Jan 07 20:02:49 2019
## -----
##
## Class specified by attribute `outcome'
##
## Read 2467 cases (17 attributes) from undefined.data
##
## ----- Trial 0: -----
##
## Rules:
##
## Default class: MITJA
##
## *** boosting reduced to 1 trial since last classifier is very inaccurate
##
## *** boosting abandoned (too few classifiers)
##
## Evaluation on training data (2467 cases):
##
##           Rules
## -----
##      No      Errors
##
##      0 1230(49.9%)  <<
##
##      (a)  (b)  (c)  <-classified as
##      ----  ----  ----
##                618  (a): class ALT
##                612  (b): class BAIX
##                1237 (c): class MITJA
##
##
## Time: 0.0 secs
```



Bibliografia

[1] Daniel T. Larouse, Chantal D. Larouse: Data Mininig and Predictive Analytics.USA, John Wiley & Sons,2015,ISBN 978-1-118-11619-7

[2] Jordi Gironés Roig, Jordi Casas Roma, Julià Minguillón Alfonso, Ramon Caihuelas Quiles : Minería de Datos: Modelos y Algoritmos. Barcelona, Editorial UOC, 2017, ISBN: 978-84-9116-904-8.

[3] Jiawe Han, Michellie Chamber & Jian Pei: Data mining : concepts and techniques. 3º Edition. USA, Editorial Elsevier, 2012, ISBN 978-0-12-381479-1

[4] Megan Squire (2105),Clean Data. Packt Publishing Ltd.